Autoencoder recurrente sobre ciclos de marcha

Diagnóstico, mejoras validadas y lo que no funcionó

Práctica Investigativa III
Seguimiento del avance – noviembre de 2026

Resumen en una diapositiva

Qué se encontró

- Se trabajó con una misma red recurrente (GRU) en dos variantes: **A**, entrenada con ciclos limpios (reconstruir), y **B**, entrenada con ciclos dañados (corregir). Ambas tenían el mayor error entre los modelos que aprenden de los datos en la comparación inicial.
- Dos defectos fueron identificados: olvido del código en el decodificador y ciclos que no cierran.
- Dos cambios pequeños los corrigieron. La mejora fue validada con 5 semillas y prueba t pareada.
- La mayoría de las ideas adicionales no aportó mejoras; eso acota dónde está el límite (datos).

	Inicial	1 modelo	Ensamble
A: MAE (°)	5.17	4.11	**3.91**
A: salto (°)	4.94	0.87	**0.55**
B: MAE (°)	5.35	4.83	**4.74**
B: salto (°)	3.45	0.57	**0.36**
B: corrección	0.280	0.337	**0.349**

1 modelo: promedio de 5 semillas. Ensamble: promedio de las predicciones de 5 modelos (un solo ensamble). Ambos modelos se evalúan con las mismas métricas. Negrilla: mejor cifra de cada fila.

Contexto: qué es un ciclo y qué se pretende

- Un ciclo de marcha es una zancada completa, remuestreada a 101 puntos (0–100% del ciclo).
- Seis ángulos sagitales: cadera, rodilla y tobillo, izquierda y derecha. Cada ciclo es una matriz $G \in \mathbb{R}^{101\times 6}$.
- Datos: 461 ciclos válidos de 64 personas, estimados por video a 30 fps.

Dos usos del modelo

Fidelidad: reconstruir un ciclo con el menor error posible.
Corrección: dado un ciclo atípico, devolver una versión típica.

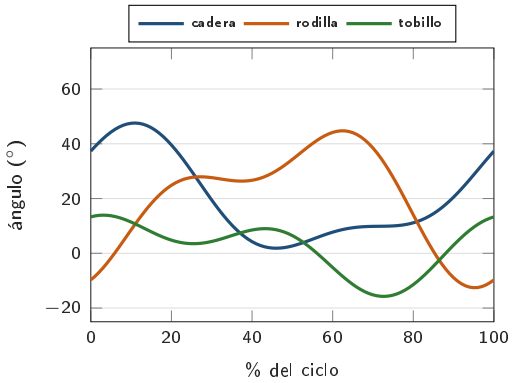
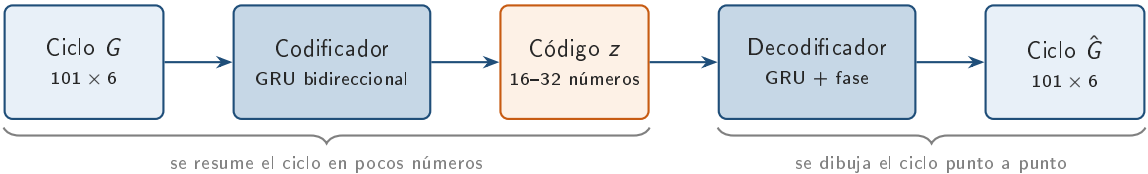


Ilustración esquemática de un ciclo (no son datos reales).

El autoencoder: comprimir y reconstruir



Analogía

Describir una canción en una frase y pedir a otra persona que la tararee a partir de esa frase. Si la frase es buena, la melodía se recupera.

Pérdida original

Error cuadrático medio entre G y $\hat{G}$ (ángulos estandarizados). Nada en esa pérdida exige que $\hat{G}$ sea *periódico*.

De dónde vienen los modelos: A y B

Nombre en el cuaderno	Nombre aquí
`control_mean`	media de controles
`pca`	PCA
`autoencoder_1d`	autoencoder convolucional
`denoising_autoencoder_1d`	autoencoder convolucional denoising
`rnn_autoencoder`	**modelo A**
`denoising_rnn_autoencoder`	**modelo B**
`gp_periodic_residual`	proceso gaussiano periódico

Cuaderno de origen

`10_cycle_manifold_models.ipynb`
Ruta: `01-experimentation/notebooks/`
Datos: generados por `09_cycle_manifold_data_preparation.ipynb`
Resultados: `01-experimentation/outputs/cycle_manifold_models/`

A y B: misma red, distinto entrenamiento

A: recibe ciclos limpios y debe devolverlos.
B: recibe ciclos dañados (amplitud, desplazamiento, ruido, corrimiento de fase) y debe devolver el ciclo limpio.

Qué mide cada métrica (las mismas para todos los modelos)

Evaluación	Datos	Métrica	Lectura
I. Fidelidad	47 ciclos limpios de control no vistos	MAE (°)	error medio punto a punto; menor es mejor
		Salto de cierre (°)	|salida(0%) − salida(100%)|; menor es mejor
II. Corrección	los mismos ciclos, dañados artificialmente	Ganancia de corrección	$1 - \frac{\mathrm{MAE}(\text{salida},\text{limpio})}{\mathrm{MAE}(\text{dañado},\text{limpio})}$; mayor es mejor
III. Casos externos	130 ciclos del grupo de casos	Ganancia de tipicidad	$1 - d_{\text{salida}}/d_{\text{entrada}}$, d = distancia al control más cercano; mayor es mejor
		Intervención (°)	cuánto cambia la salida respecto a la entrada (no hay "mejor")

A y B no tienen métricas distintas

Todas las métricas se aplican a todos los modelos. Cambia *en cuáles destaca cada uno*: A fue entrenado para copiar (se compara sobre todo en I) y B para corregir (se compara sobre todo en II). Si una tabla muestra solo algunas métricas, son las que el cambio probado podía mover.

Punto de partida: comparación inicial de modelos

	MAE (°)	Salto (°)	Corrección	Tipicidad	Intervención (°)
Media de controles	8.77	**0.60**	−0.121	0.132	10.83
PCA	**2.78**	3.41	0.207	0.127	3.86
Autoencoder convolucional	3.30	3.11	0.252	0.182	4.83
Autoencoder convolucional denoising	4.07	1.88	**0.412**	0.376	5.98
Proceso gaussiano periódico	3.30	**0.60**	0.215	0.192	3.86
Modelo A	5.17	4.94	0.152	0.349	8.12
Modelo B	5.35	3.45	0.280	**0.385**	7.89

Qué se observa

Entre los modelos que aprenden de los datos, A y B tienen el mayor error y los mayores saltos. B tiene la mayor ganancia de tipicidad (0.385); la mayor ganancia de corrección es la del autoencoder convolucional denoising (0.412).

Nota

Cifras del cuaderno original, conjunto de control no visto (fidelidad, corrección) y casos externos (tipicidad, intervención). A y B tienen las cinco columnas. Negrilla: mejor valor de la columna (el salto de 0.60 de la media de controles es trivial: promedia ciclos).

Diagnóstico: dos causas probables del bajo desempeño

1. Olvido

El código z solo entra como estado inicial. Tras 101 pasos, la memoria se diluye.

Analogía: dictar una dirección una única vez y esperar que se recuerde cien pasos después.

Remedio: entregar z en cada paso.

2. El ciclo no cierra

La pérdida solo mide error punto a punto. Si el último punto queda lejos del primero, no hay castigo específico.

Analogía: una curva que no se une consigo misma deja una "costura" visible al encadenar zancadas.

Remedio: penalizar $|\hat{G}(0) - \hat{G}(100)|$.

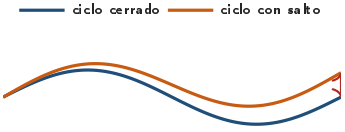


Ilustración esquemática.

Protocolo de evaluación

Datos y entrenamiento

- Partición por sujeto (sin fuga entre ciclos de una misma persona).
- Entrenamiento: 240 ciclos / 28 sujetos. Validación: 44 / 6. Prueba de control: 47 / 7. Casos externos: 130 / 23.
- Estandarización con estadísticas del entrenamiento.
- Optimizador adaptativo (tasa 10^{-3}), lote 64, hasta 100 épocas, parada temprana (paciencia 12), 48 unidades ocultas.

Tres evaluaciones

I. Reconstrucción de ciclos limpios (MAE, salto).
II. Corrección de ciclos *dañados* artificialmente (ganancia de corrección).
III. Casos externos (tipicidad e intervención).

Regla de validación

Explorar con una semilla; afirmar solo con **cinco semillas** (42, 1, 7, 123, 2024) y prueba t pareada.

Por qué cinco semillas

- Con 240 ciclos de entrenamiento, una misma configuración cambia de resultado según el azar inicial.
- El RNN original fluctuó $\pm 0.23°$ en MAE y $\pm 0.55°$ en salto.
- Una mejora de décimas observada con una sola semilla no es evidencia.
- Cada variante fue comparada *semilla a semilla*; el valor *p* resume si la ventaja se repite.

Ejemplo: mismo modelo, cinco semillas

Semilla	MAE (°)	Salto (°)
42	4.182	1.140
1	4.208	1.494
7	4.234	1.198
123	4.178	1.358
2024	4.176	1.433

Runa repetida + cierre, latente 16. El salto varía de 1.14 a 1.49 sin cambiar nada más.

Mapa de experimentos

Funcionan (5 semillas; 7: un ensamble)

1	Código en cada paso	Sí
2	Pérdida de cierre	Sí
3	Ambos juntos	Sí
5	Extensión a denoising	Sí
6	Latente 32, $w = 0.1$ (A)	Sí
7	Ensamble de 5 semillas	Sí

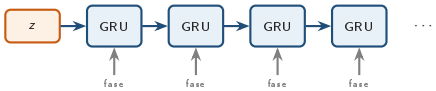
No confirmados

4	Suavidad (1.ª y 2.ª diferencia)	No
8	Decodificador bidireccional	No
9	Atención en el codificador	No
10	Velocidad / asimetría como entrada	No
11	Consistencia del latente	Neutro
12	Intensidad y currículo de corrupción	Neutro
13	Peso de cierre $w = 0.07$ (denoising)	Menor
14	Latentes 32/48/64 (denoising)	Neutro
15	Ensamble mixto A + B	No
16	Otras lecturas de t y $t - 1$	Neutro
17	Modelo fundacional congelado	No
18	Codificador lineal (control)	Mixto

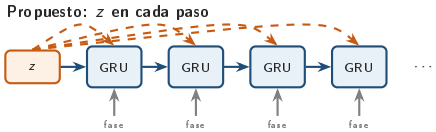
Neutro: diferencia dentro del ruido o sin significancia. Menor: mejora pequeña (salto $0.57 \rightarrow 0.47$, $p = 0.022$). El 16 mejora la forma de la curva, no el error. Mixto: mejor MAE que el GRU, peor cierre.

Mejora 1: el código en cada paso del decodificador

Original: z solo al inicio



Propuesto: z en cada paso



Intuición

Es la diferencia entre dictar la receta una sola vez y tenerla a la vista durante toda la cocción.

Resultado (una semilla)

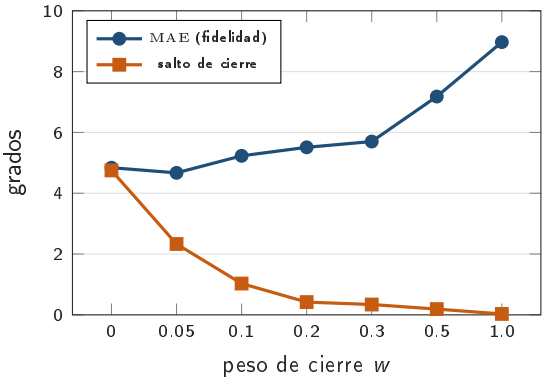
MAE: **4.84°** → **4.22°**. El salto baja poco (4.75° → 3.9°): mejora la fidelidad, no el cierre.

Mejora 2: penalizar que el ciclo no cierre

Pérdida

$$\mathcal{L} = \underbrace{\text{mean}(\hat{G} - G)^2}_{\text{fidelidad}} + w \underbrace{\text{mean}\,|\hat{G}(0) - \hat{G}(100)|}_{\text{cierre}}$$

- El peso w regula la exigencia del cierre.
- Existe un compromiso: w grande fuerza el cierre pero resta libertad a la curva.
- Se selecciona un valor pequeño (0.05–0.1): el salto cae de 4.75° a 2.3–1.0° y el error cambia poco (una semilla).



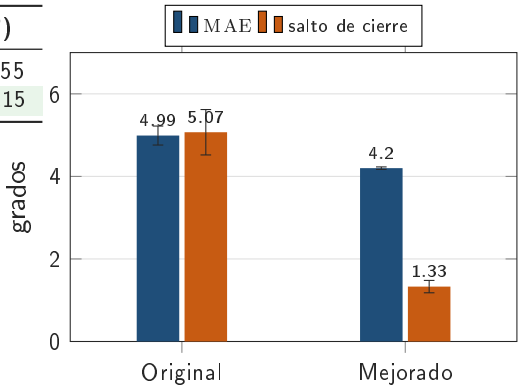
Pérdida de cierre aplicada sola, una semilla.

Mejoras 1 + 2 juntas: validación con cinco semillas

	MAE (°)	Salto (°)
RNN original (reproducido)	4.99 ± 0.23	5.07 ± 0.55
Código por paso + cierre	4.20 ± 0.03	1.33 ± 0.15

Lectura

- Gana en las 5 semillas, en ambas métricas.
- La dispersión cae de ± 0.23 a ± 0.03: el modelo es además mucho más estable.
- Las dos mejoras son complementarias: una reduce error, la otra cierra el ciclo.



Media $\pm$ desviación estándar, 5 semillas.

Sugerencia: penalizar la diferencia entre t y $t-1$

Lo probado

Penalización sobre diferencias consecutivas de la salida (suavidad) y sobre la segunda diferencia (aceleración), sola y combinada con el cierre.

Peso de suavidad	0	0.2	3.0
MAE (°)	4.219	**4.215**	4.451
Salto (°)	3.912	**3.907**	5.862

Una semilla. Aceleración y combinación con cierre: mismo patrón (MAE 4.18 en todos los casos).

Por qué no aporta

Una GRU ya produce salidas suaves: su estado cambia gradualmente. Se pedía algo que ya se cumplía.

Qué sí captura la idea

El problema no estaba *dentro* del ciclo sino en la costura: el vecino anterior ($t-1$) del punto 0 es el punto 100. Esa diferencia, que cruza el borde, es precisamente la pérdida de cierre.

Otras lecturas: siguientes diapositivas.

Otras lecturas de t y $t-1$

Lectura	Intuición	Resultado exploratorio (1 semilla)
Suavidad circular	Penalizar $\lvert\hat{G}_t - \hat{G}_{t-1}\rvert$ contando también el paso del punto 100 al 0	Cierra solo en parte: salto 3.1° frente a 3.9° sin nada y 1.1° con la pérdida de cierre
Curvatura circular	Penalizar la segunda diferencia: evitar "esquinas", también en la costura	Baja pendiente en la costura y rugosidad; el error no cambia
Igualar incrementos	Exigir que el cambio de $t-1$ a t se parezca al *real*, no solo el valor	Mejora levemente el error en incrementos; el salto de cierre sube
Pendiente en la costura	Exigir que la pendiente final iguale la inicial (continuidad de la derivada)	Pendiente $1.38 \rightarrow 0.13$, con pequeño costo en error
Kernel periódico	Puntos cercanos en fase circular deben tener valores cercanos (como en el proceso gaussiano)	Con peso fuerte el error sube a 4.98°; con peso suave no aporta
Peso por fase	Más peso al error cerca de los extremos del ciclo	Error 4.11°, pero el salto de cierre sube a 3.3°

Nuevas métricas de forma (grados; menor es mejor)

Pendiente en la costura: diferencia entre pendiente final e inicial ("quiebre" visible al encadenar zancadas). **Error en incrementos**: si los cambios paso a paso se parecen a los reales. **Rugosidad**: promedio de la segunda diferencia.

Otras lecturas: validación con cinco semillas

	MAE	Salto	Pend. costura	Err. increm.	Rugosidad
Referencia, $w = 0.05$	4.20 ± 0.03	1.33 ± 0.15	1.15 ± 0.19	0.578 ± 0.007	0.118 ± 0.003
Referencia, $w = 0.1$	4.24 ± 0.03	0.83 ± 0.07	1.15 ± 0.16	0.581 ± 0.008	0.118 ± 0.004
Incrementos, $w = 0.1$	4.21 ± 0.03	0.99 ± 0.12	0.70 ± 0.09	0.557 ± 0.005	0.110 ± 0.002
Incrementos + curvatura	4.21 ± 0.03	0.95 ± 0.10	0.58 ± 0.07	0.553 ± 0.003	0.104 ± 0.002
Incrementos + pendiente	4.24 ± 0.06	0.96 ± 0.06	0.19 ± 0.02	0.553 ± 0.006	0.106 ± 0.001
Curvatura (peso 3), $w = 0.05$	4.25 ± 0.03	0.96 ± 0.09	0.52 ± 0.04	0.567 ± 0.007	0.094 ± 0.002
Ciclos reales	–	6.0	0.81	–	0.226

Lectura

Con el mismo $w = 0.1$, igualar incrementos reduce el error en solo 0.03° ($p = 0.008$; efecto práctico nulo), la pendiente en la costura (-39%), error en incrementos (-4%) y rugosidad (-7%; todos $p < 0.01$); el salto de cierre sube de 0.83° a 0.99°. Negrilla: mejor valor de la columna. En el modelo denoising el patrón se repite (pendiente $1.03 \rightarrow 0.58$; error y corrección sin cambio).

Hallazgo

Los ciclos reales no cierran: salto medio de $\approx 6^\circ$. Cerrar el ciclo es un supuesto de periodicidad, no fidelidad a la medición; por eso estas penalizaciones mejoran la *forma*, no el error.

Variante denoising: aprender a corregir

Receta de entrenamiento

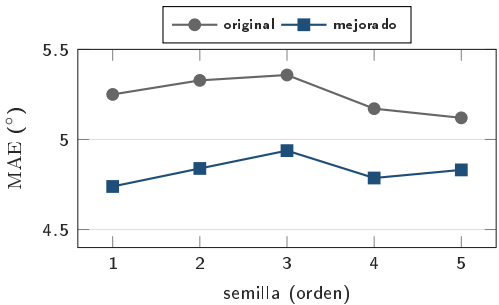
Cada ciclo es dañado de forma aleatoria y la salida debe coincidir con el ciclo *limpio*:

- amplitud $\times U(0.5, 1.8)$,
- desplazamiento vertical $U(-0.9, 0.9)$,
- ruido de desviación 0.15,
- corrimiento de fase de hasta ± 8 puntos.

Analogía: restaurar una pintura estropeada; se aprende cómo *debería* verse.

Mejoras 1 y 2 aplicadas igualmente a esta variante.

	Original	Mejorado	p
MAE (°)	5.25 ± 0.10	4.83 ± 0.07	**0.0005**
Salto (°)	3.04 ± 0.31	0.57 ± 0.05	< 0.001
Corrección	0.296 ± 0.014	0.337 ± 0.007	**0.0019**
Tipicidad	0.383 ± 0.004	0.414 ± 0.008	**0.0011**



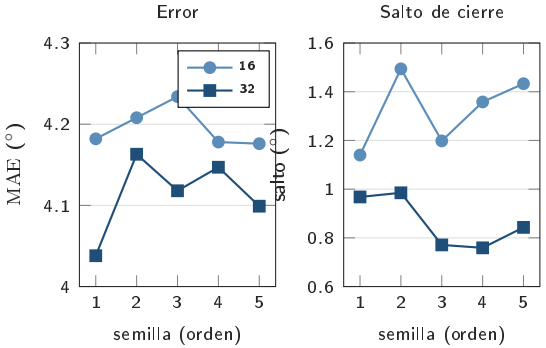
Modelo A: latente de 32 números y re-ajuste del cierre

- Con latente 16 el mejor peso era $w = 0.05$; con 32, $w = 0.1$.
- Con más capacidad, la red puede "sortear" el cierre con más detalle; la penalización debe ser más exigente.

	MAE	Salto
16, w=0.05	4.20 ± 0.03	1.33 ± 0.15
32, w=0.1	4.11 ± 0.05	0.87 ± 0.11
p	**0.018**	**0.004**

Lección

Los hiperparámetros dependen entre sí. Cambiar el latente sin re-ajustar w habría conducido a una conclusión errónea.



El latente 32 gana en las 5 semillas en ambas métricas.

Ensamble de cinco semillas

Idea

Entrenar 5 modelos con semillas distintas y promediar sus salidas.

- Cada modelo se equivoca algo distinto por azar; al promediar, el azar se cancela parcialmente, como al promediar varias mediciones.
- Lo que *no* se cancela es un error sistemático (compartido por todos).
- Por eso mezclar modelos de objetivos distintos (A y B) da un resultado intermedio, no mejor.

	MAE	Salto	Corr.
A, 1 modelo	4.11	0.87	–
A, ensamble	**3.91**	0.55	0.229
B, 1 modelo	4.83	0.57	0.337
B, ensamble	4.74	**0.36**	**0.349**
A + B (10 modelos)	4.16	0.39	0.319

A: entrenado con ciclos limpios. B: con ciclos dañados. Un solo ensamble por fila; su incertidumbre no fue medida. Negrilla: mejor valor de la columna.

Lo que no funcionó (y qué enseña)

Experimento	Resultado	Explicación probable
Decodificador bidireccional	MAE 4.244 / salto 3.920 frente a 4.219 / 3.912 (misma configuración, sin cierre)	Ya recibe z y fase en cada paso; mirar hacia atrás no agrega información
Atención en el codificador	MAE $\approx 8.5^{\circ}$; pesos casi uniformes ($\approx 1/101$)	Con 240 ciclos no se aprende dónde mirar; degenera en promedio
Velocidad angular como entrada	MAE 4.728 $\rightarrow$ 4.822	La derivada amplifica el ruido de la estimación por video
Asimetría izquierda-derecha	MAE 4.728 $\rightarrow$ 4.771	La información ya está en los seis canales
Consistencia del latente	MAE 4.833 vs 4.835 ($p = 0.85$)	El denoising ya induce códigos parecidos
Intensidad de corrupción	Corrección 0.320 / 0.349 / 0.329 para intensidad 0.5 / 1.0 / 1.5 (MAE 4.45 / 4.73 / 5.12)	U invertida: óptimo en 1.0; la receta original estaba calibrada
Currículo de corrupción	MAE 4.83 $\rightarrow$ 4.79 ($p = 0.26$)	Dentro del ruido entre semillas
Ensamble mixto A + B	MAE 4.16, corrección 0.319 (intermedio)	Objetivos distintos; ver “Dos modelos, dos trabajos”

Conclusión de los resultados negativos

Lectura de conjunto

Casi toda adición de componentes aprendibles (atención, más entradas, términos extra) no aportó. El cuello de botella parece ya no ser la arquitectura sino el **tamaño de los datos**: 240 ciclos de 28 personas.

- Con pocos datos, agregar parámetros agrega más ruido que señal.
- Las dos mejoras que funcionaron son *restricciones* simples (entregar z, cerrar el ciclo), no componentes nuevos.

Implicación

Los próximos avances más probables provienen de:

- más datos o aumento de datos realista,
- restricciones físicas adicionales,
- mejor selección de hiperparámetros (validación cruzada por sujeto).

Dos modelos, dos trabajos

	A (ciclos limpios)	**B** (ciclos dañados)
Entrenamiento	ciclo limpio → mismo ciclo	ciclo dañado → ciclo limpio
Pregunta	¿Qué tan fielmente se reconstruye?	¿Cómo sería la versión típica?
Fortaleza	mejor MAE de las dos (**3.91°**, ensamble)	mejor corrección de las dos (**0.349**, ensamble)
Riesgo	reproduce también lo anómalo	se aleja algo de la entrada

Analogía

A es una fotocopiadora de alta calidad (copia incluso los defectos). B es un restaurador (devuelve cómo debería verse). Un ensamble mixto es una fotocopiadora que a veces restaura: queda en un punto intermedio (MAE 4.16°, corrección 0.319).

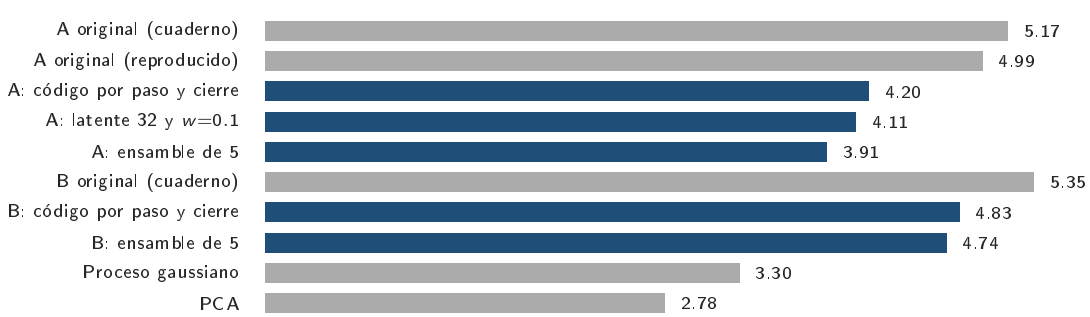
¿Por qué no PCA (MAE 2.78°)?

PCA reproduce muy bien, pero justamente por eso reproduce también lo atípico: su ganancia de tipicidad es la más baja de la comparación (0.127, frente a 0.349 y 0.385 de A y B originales).

Para fidelidad pura, PCA sigue siendo superior; el RNN aún no la alcanza. B supera a PCA en corrección (0.349 frente a 0.207), pero queda por debajo del autoencoder convolucional denoising del cuaderno original (0.412).

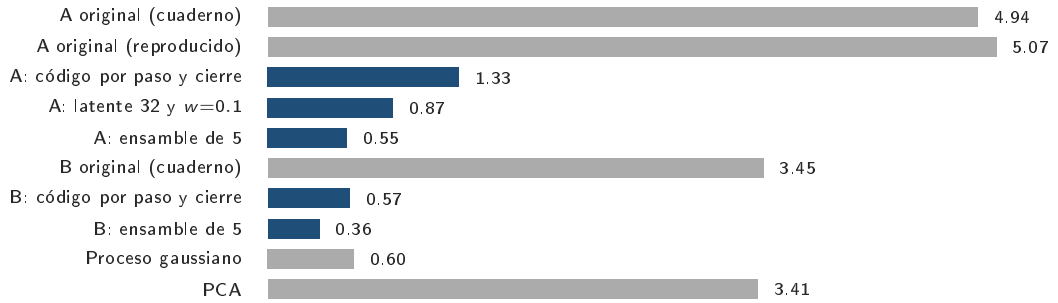
Nota: la tipicidad alta de A original (0.349) coincide con una intervención grande (8.12°) por su error alto; no es corrección deliberada.

Escalera de mejora: error de reconstrucción



Gris: referencias. Azul: versiones mejoradas. Barras de un modelo = promedio de 5 semillas; "ensamble" = un ensamble de 5.

Escalera de mejora: cierre del ciclo



El salto de los modelos mejorados cae a 0.4–0.9° (−82 a −90%); B y los ensambles igualan o superan al proceso gaussiano periódico (0.60°), y A en un modelo (0.87°) queda algo por encima.

Cuánto se mejoró

	Inicial	1 modelo	Ensamble de 5
A: MAE (°)	5.17	4.11 (−20%)	**3.91** (−24%)
A: salto (°)	4.94	0.87 (−82%)	**0.55** (−89%)
B: MAE (°)	5.35	4.83 (−10%)	**4.74** (−11%)
B: salto (°)	3.45	0.57 (−84%)	**0.36** (−90%)
B: corrección	0.280	0.337 (+20%)	**0.349** (+25%)

1 modelo: promedio de 5 modelos entrenados por separado (cifra validada). Ensamble: promedio de las predicciones de esos 5 modelos; es mejor, pero proviene de un único ensamble y cuesta cinco modelos. Negrilla: mejor cifra de cada fila.

Dos comparaciones posibles

Los porcentajes comparan contra las cifras del cuaderno inicial.
Contra la *reproducción* del modelo inicial con el mismo protocolo (4.99 y 5.25 de MAE), la mejora en fidelidad es algo menor: −18% (A) y −8% (B).
La segunda comparación es la más estricta.

Veredicto: qué modelo es mejor y cuánto mejoró

Respuesta directa

El **modelo A mejorado es el mejor para reconstruir** y el **modelo B mejorado es el mejor para corregir**; ninguno gana en todo. Con ensamble de 5, A alcanzó un MAE de **3.91°** (original 5.17°; −24%) y un salto de cierre de **0.55°** (original 4.94°; −89%). Con ensamble de 5, B alcanzó una ganancia de corrección de **0.349** (original 0.280; +25%), con MAE de **4.74°** (original 5.35°; −11%) y salto de **0.36°** (original 3.45°; −90%). Como modelo individual: A, 4.11° y 0.87°; B, corrección 0.337, 4.83° y 0.57°.

Objetivo	Mejor	Ensamble (1 modelo)	Rival
Fidelidad (MAE)	**A**	**3.91°** (4.11°)	B: 4.74°
Cierre (salto)	**B**	**0.36°** (0.57°)	A: 0.55°
Corrección	**B**	**0.349** (0.337)	A: 0.229

Salvedades

PCA sigue mejor en MAE (2.78°); el autoencoder convolucional denoising sigue mejor corrigiendo (0.412). A no mejoró su corrección (0.208 → 0.189; $p = 0.077$) y su tipicidad bajó algo (0.345 → 0.326). Un codificador lineal con el mismo decodificador alcanza 3.26° de MAE en ensamble (control).

Entonces, ¿por qué no PCA ni el convolucional denoising?

	MAE (°)	Salto (°)	Corr.
PCA	**2.78**	3.41	0.207
Proceso gaussiano periódico	3.30	0.60	0.215
Conv. denoising	4.07	1.88	**0.412**
A mejorado (ensamble)	3.91	0.55	0.229
B mejorado (ensamble)	4.74	**0.36**	0.349

Negrilla: mejor valor de la columna. RNN: un único ensamble tras las mejoras; resto: cuaderno original, una corrida.

Conclusión

Con las cifras actuales **no hay una razón basada en métricas** para preferir la RNN: PCA gana en fidelidad y el convolucional denoising en corrección. La RNN solo queda al frente en cierre de ciclo, y por poco.

La comparación favorece a la RNN

Sus hiperparámetros fueron afinados sobre el conjunto de control; los de PCA y del convolucional no, y sus cifras son de una sola corrida. Aun así, la RNN no los supera.

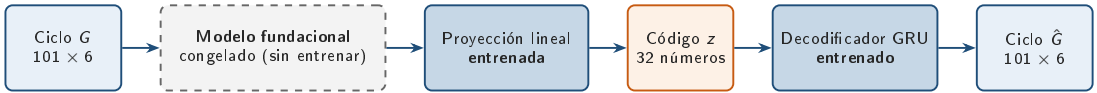
Razones posibles para mantener la RNN

Decisión de diseño del proyecto, o necesidades de la aplicación (dinámica en el tiempo, ciclos de distinta longitud). Ninguna fue medida; debe ser confirmada.

Propuesta

1. Definir si se mejora la RNN por diseño o se busca el mejor modelo.
2. Aplicar cierre de ciclo (y código por paso) al convolucional denoising.
3. Reevaluar PCA y el convolucional con 5 semillas y el mismo protocolo.

Experimento adicional: modelo fundacional como codificador



Idea y diseño

Se evalúa si las representaciones de un modelo de series de tiempo preentrenado (TimesFM 2.5, 200 millones de parámetros) sirven como código del ciclo.

- Cada canal se remuestrea a 128 puntos (4 parches). Del estado interno de un bloque se promedian los parches y se toma el último; se añaden la media y la desviación de la serie, que el modelo descarta al normalizar.
- Se entrenan solo la proyección lineal y el decodificador (el de la mejora 1, con cierre).
- Mismos datos, partición, pérdida, métricas y 5 semillas que el modelo mejorado. Tipo A: latente 32, $w = 0.1$. Tipo B: latente 16, $w = 0.05$.
- La configuración (bloque, agrupación, decaimiento de pesos) fue elegida solo con validación, con una semilla.

Dos controles

- **Pesos aleatorios:** misma arquitectura sin preentrenar (normas internas con escala uno). Separa el aporte del preentrenamiento del de la arquitectura.
- **Serie cruda:** la serie estandarizada entra directamente a la proyección lineal. Indica qué se logra sin ningún modelo preentrenado.

Prueba de sanidad de los pesos

Pronóstico de una onda seno: error de **0.036** con pesos preentrenados y de 1.877 con pesos aleatorios. Los pesos se cargaron correctamente.

Resultado: el modelo fundacional congelado no mejora

Tipo A (autoencoder limpio)

	MAE (°)	Salto (°)	Correc.	Tipic.
Preentrenado	7.19 (6.76)	2.55	−0.149	0.101
Pesos aleatorios	7.23 (6.66)	2.74	−0.017	0.087
Serie cruda	**3.69** (3.26)	1.40	0.011	0.181
GRU mejorado	4.11 (3.91)	**0.87**	**0.189**	**0.326**

Tipo B (con eliminación de ruido)

	MAE (°)	Salto (°)	Correc.	Tipic.
Preentrenado	10.12 (9.76)	6.80	−0.117	−0.049
Serie cruda	**4.46** (4.33)	1.28	**0.380**	0.390
GRU mejorado	4.83 (4.74)	**0.57**	0.337	**0.414**

Promedio de 5 semillas (ensamble de las 5 entre paréntesis, solo MAE). Salto: cierre del ciclo. Negrilla: mejor valor de la columna en cada tabla.

Lectura

- El preentrenamiento **no aporta en fidelidad**: MAE de 7.19° con pesos preentrenados y 7.23° con aleatorios ($p = 0.83$). El salto no difiere ($p = 0.19$) y la corrección es peor con pesos preentrenados ($p = 0.004$).
- Es peor que el GRU mejorado en fidelidad, cierre, corrección y tipicidad ($p \leq 0.003$, 5 semillas, sin corrección por multiplicidad).
- Tipo B: entrenamiento detenido pronto (20 a 42 épocas) y corrección negativa.

Alcance de la conclusión

Vale para este diseño (un modelo, representaciones congeladas agrupadas, proyección lineal, 240 ciclos de entrenamiento y 15 372 características). No se probaron otros modelos, conservar los cuatro parches ni afinar el codificador.

Hallazgo de los controles: un codificador lineal basta

		Lineal	GRU	p
A	MAE (°)	**3.69**	4.11	0.002
	Salto (°)	1.40	**0.87**	0.001
	Corrección	0.011	**0.189**	< 0.001
	Tipicidad	0.181	**0.326**	< 0.001
B	MAE (°)	**4.46**	4.83	< 0.001
	Salto (°)	1.28	**0.57**	< 0.001
	Corrección	**0.380**	0.337	< 0.001
	Tipicidad	0.390	**0.414**	0.007

Lineal: proyección lineal de la serie cruda al código y el mismo decodificador GRU con cierre. GRU: codificador recurrente (modelo mejorado). Promedio de 5 semillas; p: prueba t pareada. Negrilla: mejor valor de cada fila.

Qué indica

Sustituir el codificador recurrente por una proyección lineal *reduce el error de reconstrucción* en A y B y *mejora la corrección* en B. Entonces, el codificador GRU no parece ser lo que limita el rendimiento; es consistente con que PCA, también lineal, tenga el menor MAE.

Salvedades

- Surgió de un control, no de una hipótesis previa.
- El lineal pierde en cierre, pendiente de la costura y (en A) en corrección y tipicidad.
- Los hiperparámetros del GRU fueron afinados sobre el conjunto de control; los del lineal no. La comparación favorece al GRU y aun así pierde en MAE.

Limitaciones y salvedades

1. Los hiperparámetros fueron elegidos observando el conjunto de prueba de control; las cifras finales son algo optimistas.
2. Los latentes 32/48/64 en el modelo denoising no se distinguen (modelos individuales, 16 frente a 32, 5 semillas: MAE $p = 0.52$; corrección $p = 0.18$).
3. Cada ensamble proviene de un único conjunto de 5 modelos.
4. La evaluación de corrección usa una sola realización del daño aleatorio (con otra, la corrección de B mejorado pasó de 0.337 a 0.32).
5. Datos reconstruidos de los archivos entregados; las cifras reproducidas difieren algo del cuaderno inicial (4.99 vs 5.17; 5.25 vs 5.35).
6. Otras lecturas de t y $t-1$: validadas solo en A (dos en B); por confirmar.
7. El autoencoder convolucional no se reevaluó con 5 semillas.
8. El experimento con modelo fundacional cubre un solo diseño y un solo modelo; la configuración se eligió con una semilla.

Cómo se mitigó

Partición por sujeto, cinco semillas con prueba pareada para toda afirmación, y reporte explícito de los resultados negativos.

Conclusiones

1. El autoencoder recurrente presentaba dos defectos concretos: olvido del código y falta de cierre del ciclo.
2. Entregar z en cada paso y penalizar el salto de cierre redujeron el error (-20%) y el salto (-82%) del modelo A (un modelo), con menor variabilidad entre semillas.
3. La misma receta mejoró el modelo B (un modelo): cierre (-84%) y corrección ($+20\%$); en ensamble, corrección $+25\%$.
4. A (fidelidad, MAE 3.91° en ensamble) y B (corrección, 0.349 en ensamble) cumplen funciones distintas y no deben mezclarse.
5. La mayoría de las ideas adicionales no aportó; el límite actual parece ser la cantidad de datos.
6. La fidelidad de PCA (2.78°) aún no fue alcanzada por el RNN, aunque PCA no corrige hacia lo típico.
7. Un modelo fundacional congelado (TimesFM) no mejoró: su MAE fue igual al de pesos aleatorios y peor que el del GRU. Un codificador lineal sobre la serie cruda superó al codificador GRU en MAE.

Preguntas para discusión y próximos pasos

Preguntas abiertas

- De las lecturas probadas de t y $t-1$, ¿cuál se acerca más a lo previsto? ¿Interesa más la forma de la curva o el error?
- ¿Qué error de reconstrucción o de corrección resulta suficiente para la aplicación?
- ¿Se prioriza fidelidad (A) o corrección (B) como modelo de referencia?
- ¿Se mejora la RNN por diseño o se busca el mejor modelo (PCA gana en fidelidad; el convolucional denoising, en corrección)? Dado que un codificador lineal basta, ¿se mantiene el codificador recurrente?

Próximos pasos propuestos

1. Aplicar las mejoras al convolucional denoising y reevaluarlo, con PCA, con 5 semillas.
2. Validación cruzada por sujeto para elegir hiperparámetros.
3. Repetir ensambles para medir su incertidumbre y decidir entre latentes 32/48/64.
4. Evaluar los modelos finales en casos externos (evaluación III).
5. Explorar más datos o aumento de datos realista.
6. Probar variantes del modelo fundacional (sin promediar los parches, otros modelos) y medir el codificador lineal con ajuste propio.

Anexo: resultados por semilla (modelo denoising)

	MAE (°)		Salto (°)		Corrección	
Semilla	inicial	mejorado	inicial	mejorado	inicial	mejorado
42	5.250	4.739	3.194	0.590	0.298	0.348
1	5.328	4.839	3.418	0.598	0.281	0.332
7	5.358	4.938	3.040	0.525	0.283	0.333
123	5.171	4.786	2.998	0.512	0.304	0.333
2024	5.120	4.831	2.569	0.611	0.313	0.339
Media $\pm$ d.e.	5.25 ± 0.10	4.83 ± 0.07	3.04 ± 0.31	0.57 ± 0.05	0.296 ± 0.014	0.337 ± 0.007

Anexo: ensambles y peso de cierre (denoising)

Ensambles de 5 modelos

Configuración	MAE	Salto	Corr.
16, $w = 0.05$	4.743	0.361	0.349
16, $w = 0.07$	4.746	0.290	0.349
32, $w = 0.1$	4.682	0.286	0.357
48, $w = 0.1$	4.670	**0.248**	0.359
64, $w = 0.1$	**4.554**	0.304	**0.369**

Un ensamble por fila; no se midió cuánto varía un ensamble de otro, así que no se sabe si las diferencias son reales. Negrilla: mejor valor de la columna.

Peso de cierre (latente 16, una semilla)

w	MAE	Salto	Corr.
0.02	4.731	1.002	0.347
0.03	4.729	0.693	**0.349**
0.05	4.741	0.585	0.348
0.07	**4.728**	0.460	**0.349**
0.10	4.753	0.624	0.346
0.15	4.787	**0.324**	0.343

Con 5 semillas, $w = 0.07$ reduce el salto ($0.57 \to 0.47$, $p = 0.022$) sin cambiar MAE.